

Artesanos Conectados

Portafolio N° 5

Arquitecturas Cloud Básicas

Autor: Marcela Manzo Sagüez

Contenido

Resumen Ejecutivo.....2

Introducción.....4

1 Arquitecturas de almacenamiento de objetos y bases de datos5

1.1 Propuesta.....5

1.2 Matriz de disponibilidad, escalabilidad, resiliencia y seguridad6

2 Estrategias de almacenamiento y respaldo en la nube.....7

2.1 Propuesta.....7

2.2 Matriz de disponibilidad, escalabilidad, resiliencia y seguridad8

3 Arquitecturas de nubes públicas, privadas e híbridas.....9

3.1 Propuesta.....9

3.2 Matriz de disponibilidad, escalabilidad, resiliencia y seguridad9

4 Escalabilidad de servicios de cómputo11

4.1 Propuesta.....11

4.2 Matriz de disponibilidad, escalabilidad, resiliencia y seguridad12

5 Disponibilidad de aplicaciones en la red14

5.1 Propuesta.....14

5.2 Matriz de disponibilidad, escalabilidad, resiliencia y seguridad14

6 Disponibilidad de contenidos de aplicaciones en cloud.....15

6.1 Propuesta.....15

6.2 Matriz de disponibilidad, escalabilidad, resiliencia y seguridad15

7 Arquitecturas básicas orientadas a mensajes17

7.1 Propuesta.....17

7.2 Matriz de disponibilidad, escalabilidad, resiliencia y seguridad18

8 Administración de costos en la nube19

8.1 Supuestos técnicos por servicio (Región: us-east-1)19

8.2 Costos calculados con CloudCraft20

8.3 Resumen22

9 Conclusión23

10 Anexo: Diagrama de Arquitectura Consolidado24

Índice de Figuras

Figura 8-1: Costo de Buckets S3 = USD 3,2320

Figura 8-2: Costo RDS Multi-AZ – PostgreSQL = USD 52,0520

Figura 8-3: Costo Base NoSQL – DynamoDB = USD 6,0021

Figura 8-4: Costo Capa de Cómputo = USD 46,8021

Resumen Ejecutivo

Contexto y Desafío de Negocio

“**Artesanos Conectados**” es una plataforma chilena de comercio electrónico con un modelo dual (Marketplace B2C y distribución mayorista B2B para hoteles y boutiques). Actualmente, la empresa opera sobre una infraestructura tradicional de capacidad fija que resulta ineficiente: es incapaz de absorber los picos masivos de tráfico en fechas comerciales críticas (como Fiestas Patrias o Navidad) y genera costos ociosos durante las temporadas bajas. Esta rigidez afecta directamente los servicios core del negocio: la navegación de usuarios, la consulta del catálogo y la gestión de pedidos.

Solución Propuesta: Arquitectura de Nube Híbrida

Para resolver esta problemática de forma costo-eficiente, se diseñó una arquitectura de nube híbrida sobre Amazon Web Services (AWS) que combina la elasticidad de la nube pública con el control local de la empresa:

- **Frente Cloud Público (AWS):** Alberga todos los componentes de cara al cliente y de alta demanda. Implementa un frontend híbrido (SSR para indexación SEO y SPA para paneles/checkout), respaldado por un Auto Scaling Group y un Application Load Balancer (ALB) para ajustar el cómputo (instancias t4g.small) automáticamente según el tráfico en tiempo real.
- **Frente Local (On-Premise):** Por razones estrictas de gobernanza corporativa, conciliación contable e integración con sistemas heredados, el módulo crítico de liquidación de pagos financieros a los artesanos se mantiene en la infraestructura interna de la organización.
- **Conectividad Cifrada:** Ambos entornos se enlazan de forma privada y segura mediante un túnel AWS Site-to-Site VPN activo las 24 horas del día.

Ambos entornos se enlazan de forma privada y segura mediante un túnel AWS Site-to-Site VPN activo las 24 horas del día (ver topología visual detallada en el Anexo: Diagrama de Arquitectura Consolidado).

Pilares de la Infraestructura (Disponibilidad y Resiliencia)

La arquitectura se estructuró bajo el principio de cero pérdida de datos y tolerancia a fallos:

- **Persistencia Segura:** Los datos del catálogo y condiciones comerciales B2B residen en Amazon RDS PostgreSQL configurado en modo Multi-AZ (dos zonas de disponibilidad con replicación síncrona y failover automatizado). Los datos operacionales de alta escritura (carritos de compra y sesiones) se derivan a una capa NoSQL con Amazon DynamoDB. Los elementos binarios (fotos de alta resolución) se almacenan en Amazon S3 con versionado y réplica en la misma región.
- **Mitigación de Cuellos de Botella (Caché en el Edge):** Se despliega Amazon CloudFront como CDN, no solo para servir assets estáticos de S3, sino para almacenar en caché las respuestas del catálogo dinámico (SSR) por periodos cortos. Esto protege a la base de datos de colapsar ante ráfagas masivas de usuarios o bots de búsqueda.
- **Desacoplamiento mediante Mensajería:** El procesamiento de órdenes de compra se gestiona de forma asíncrona mediante Amazon SQS. Los pedidos se confirman al instante para el comprador, mientras procesos worker secundarios en segundo plano ejecutan la lógica interna. Ante fallas en una máquina virtual, los mensajes retornan automáticamente a la cola, eliminando cualquier riesgo de pérdida de transacciones.

Viabilidad Financiera y Resumen de Costos

Bajo una política estricta de no sobreaprovisionamiento, el presupuesto mensual de la solución ha sido sincerado mediante ingeniería de costos manual que complementa las métricas de CloudCraft. El costo operativo real de la infraestructura cloud es de USD 144,08 mensuales, desglosado de la siguiente manera:

- Almacenamiento (Amazon S3): USD 3,23
- Base de Datos (Amazon RDS Multi-AZ - Primary + Replica): USD 52,05
- Base de Datos NoSQL (Amazon DynamoDB): USD 6,00
- Cómputo Elástico (2 Instancias EC2 t4g.small): USD 24,53
- Balanceo de Carga (Application Load Balancer): USD 22,27
- Conectividad Híbrida (AWS Site-to-Site VPN): USD 36,00
- Servicios en Capa Gratuita (Lambda SSR, CloudFront CDN, SQS/SNS): USD 0,00
- **COSTO TOTAL ESTIMADO: USD 144,08 / mes**

Conclusión

Este diseño técnico dota a "Artesanos Conectados" de una plataforma moderna, elástica y de alta disponibilidad, con una inversión predecible y optimizada bajo el modelo de pago por uso de AWS. La solución mitiga por completo los riesgos de caídas en temporadas de alta demanda, protege el núcleo financiero de la organización y asegura una base escalable idónea para soportar la expansión del negocio B2C y B2B en el mercado chileno.

Introducción

“**Artisanos Conectados**” es una plataforma de comercio electrónico especializada en productos artesanales chilenos, con dos modelos de negocio: un **marketplace B2C** que conecta artesanos de distintas regiones con compradores finales, y una **modalidad B2B** orientada a tiendas, boutiques y hoteles que realizan compras de mayor volumen bajo condiciones comerciales diferenciadas.

La empresa enfrenta **variaciones significativas de demanda**, especialmente en períodos de alta actividad comercial (por ejemplo, Fiestas Patrias o Navidad), y su infraestructura actual, de capacidad fija, no responde de forma eficiente a estos picos ni aprovecha los períodos de baja demanda. Esto afecta directamente los servicios core del marketplace: consulta y publicación de productos, navegación de usuarios y gestión de pedidos.

Para resolver esto, la compañía ha decidido **modernizar su infraestructura mediante una arquitectura de nube híbrida**, combinando componentes on-premise para procesos que requieren mayor control con servicios de nube pública de AWS para las cargas que se benefician de elasticidad, escalabilidad y disponibilidad.

Objetivo de la migración a la nube

El proyecto tiene como propósito **diseñar y justificar una arquitectura cloud básica** para “Artisanos Conectados” que garantice **escalabilidad, disponibilidad y eficiencia en el uso de recursos**, integrando de forma coherente almacenamiento, cómputo, red, mensajería y administración de costos, bajo un **modelo de nube híbrida** sobre AWS.

Este objetivo será abordado progresivamente a lo largo del proyecto mediante la selección de mecanismos de almacenamiento de objetos y respaldo, la definición del modelo de implementación cloud, el diseño de mecanismos de escalabilidad y balanceo de carga, la incorporación de componentes orientados a alta disponibilidad y distribución de contenidos, la implementación de mensajería asíncrona y, finalmente, la estimación y administración de los costos de la solución. De esta manera, las decisiones tomadas en cada etapa contribuirán a construir una arquitectura integral y coherente para “Artisanos Conectados”.

Mapecto de necesidades del caso

Necesidad	Detalle en el caso
Almacenamiento de objetos	Fotos de productos, documentos de envío, archivos de facturación, logs de integración, backups de bases de datos, y datos operacionales de alto volumen (carrito, sesiones) vía DynamoDB.
Mensajería asíncrona	Notificaciones de estado de envío y procesamiento de órdenes.
Escalabilidad y balanceo de carga	Picos de tráfico en horarios punta y fechas comerciales (Fiestas Patrias, Navidad, campañas).
Alta disponibilidad (Multi-AZ)	El servicio no puede caerse: impacto directo en el negocio de artesanos y clientes B2B.
CDN	Entrega rápida de assets estáticos y contenido a usuarios en distintas regiones.
Costos	Modelo sensible al margen y al costo por cliente/transacción.
Seguridad	Protección de datos comerciales y de clientes (B2C/B2B), cifrado en reposo/tránsito y control de acceso mínimo privilegio, dado que se maneja información de pedidos y condiciones comerciales sensibles.

Nota: si bien el desarrollo detallado se centra en los flujos B2C (catálogo, compra, entrega), la arquitectura considera también el segmento B2B, señalando en cada sección cómo se integran pedidos de mayor volumen y condiciones comerciales diferenciadas.

1 Arquitecturas de almacenamiento de objetos y bases de datos

1.1 Propuesta

Se selecciona Amazon S3 como servicio de almacenamiento de objetos, por su alta durabilidad, escalabilidad automática, bajo costo y fácil integración con el resto de los servicios de AWS.

Las imágenes de los productos (fotografías en alta resolución) se almacenan en S3, utilizando la clase S3 Standard para productos activos y clases de menor costo (S3 Standard-IA o Glacier) para imágenes antiguas o productos no publicados, mediante políticas de ciclo de vida. Se habilita versionado de objetos y cifrado en reposo para garantizar seguridad e integridad.

La información estructurada de cada producto (nombre, descripción, precio, stock, categoría y datos del artesano) se almacena en una base de datos relacional (Amazon RDS). S3 se encarga exclusivamente de los archivos binarios, mientras que la base de datos gestiona los datos que requieren consultas, filtros y actualizaciones frecuentes.

Almacenamiento del Frontend Estático (frontend-prod): De igual manera, se incorpora un bucket denominado frontend-prod destinado exclusivamente a alojar los archivos estáticos de la aplicación. Al igual que el bucket de imágenes, este recurso cuenta con cifrado en reposo administrado por AWS y se configura con un acceso privado estricto mediante Origin Access Control (OAC), garantizando que el contenido solo pueda ser leído y distribuido a los usuarios a través de la red de Amazon CloudFront, sin exposición pública directa a internet.

Integración en el flujo de la arquitectura

Cuando un artesano publica un producto, el backend guarda la descripción y los datos del producto en la base de datos, y almacena la imagen correspondiente en el bucket de S3 (product-images-prod); la base de datos guarda la referencia (URL) de la imagen. Al mostrar el producto, la aplicación consulta la base de datos para obtener la descripción y la URL, y la imagen se sirve dinámicamente vía CloudFront (ver Sección 6).

Capa complementaria NoSQL (Amazon DynamoDB)

RDS es adecuado para los datos que requieren integridad relacional fuerte: catálogo, precios, stock consolidado y condiciones comerciales diferenciadas para clientes B2B. Sin embargo, para los datos operacionales de alta escritura y acceso simple por clave, se incorpora Amazon DynamoDB como capa complementaria enfocada exclusivamente en:

- Carrito de compras: Acceso muy frecuente por usuario con una estructura simple de clave-valor.
- Sesiones de usuario: Lecturas y escrituras rápidas de corta duración para mantener la persistencia del cliente en la plataforma.

Mientras que las consultas transaccionales del catálogo y stock B2B son procesadas por la función Lambda Catálogo directo a la base de datos relacional, esta capa NoSQL se conecta de forma exclusiva con la función Lambda Carrito. Esto permite persistir de manera inmediata los estados de las compras en curso y las sesiones activas, garantizando una experiencia fluida de baja latencia sin saturar el motor transaccional en RDS (ver Sección 4).

1.2 Matriz de disponibilidad, escalabilidad, resiliencia y seguridad

Componente	Disponibilidad	Escalabilidad	Resiliencia	Seguridad	Justificación de Negocio
S3 (imágenes)	SLA 99.99%, redundancia entre múltiples AZ por diseño	Escalado automático e ilimitado, sin aprovisionamiento manual	Durabilidad de 11 nueves; se mitigan errores con versionado	Cifrado en reposo (SSE-S3); bucket privado, acceso solo vía CloudFront OAC (ver Sección 6)	Sostiene la experiencia visual del catálogo — fotografía de calidad es un factor directo de conversión para compradores B2C y B2B
RDS (datos de producto)	Configuración Multi-AZ (Alta Disponibilidad nativa) con replicación síncrona en dos zonas de disponibilidad de AWS.	Escalado vertical	Mitigación de pérdida de datos mediante backups automáticos diarios. Conmutación por error (failover) automática hacia la instancia en standby en caso de fallas de infraestructura o de la zona de disponibilidad primaria	Cifrado en reposo (KMS); acceso restringido por grupo de seguridad, sin exposición pública	Sostiene el motor transaccional del negocio garantizando consistencia absoluta de precios, stock crítico y condiciones comerciales diferenciadas B2B. Al ser Multi-AZ, asegura que el proceso de compra de los clientes y el negocio de los artesanos nunca se detengan por caídas de red.
DynamoDB (carrito, sesiones)	SLA gestionado, redundancia multi-AZ por diseño	Escalado horizontal automático, alto throughput de escritura	Backups continuos (PITR) y replicación integrada	Cifrado en reposo administrado por AWS; acceso exclusivo vía IAM desde servicios internos	Sostiene operaciones de alto volumen y baja latencia (carrito, sesiones) sin comprometer la integridad del catálogo transaccional en RDS

2 Estrategias de almacenamiento y respaldo en la nube

2.1 Propuesta

Respaldo de imágenes (S3)

- Versionado de objetos: Habilitado de forma nativa en el bucket principal product-images-prod para proteger los archivos originales.
- Replicación misma región: Replicación automática y asíncrona hacia un bucket secundario dentro de la misma región (product-images-dr), destinado a planes de recuperación operativa ante contingencias lógicas o de corrupción de datos.
- Políticas de ciclo de vida: Reglas automáticas aplicadas en ambos buckets para mover las versiones antiguas o imágenes obsoletas a clases de almacenamiento de menor costo como Amazon S3 Glacier, optimizando el gasto mensual.
- Recuperación: Ante un borrado o sobrescritura accidental en product-images-prod, se restaura la versión anterior de forma inmediata gracias al versionado. Ante una falla mayor o un evento catastrófico, la plataforma conmuta su origen para recuperar y servir las imágenes directamente desde el bucket de réplica product-images-dr.
- Respaldo y Ciclo de Vida en frontend-prod: Dado que este bucket contiene código empaquetado de la interfaz, su estrategia de resiliencia se basa en la capacidad de redesplicue rápido mediante pipelines. No obstante, se habilitan políticas de ciclo de vida para eliminar versiones antiguas de compilación tras 30 días, evitando la acumulación de basura digital y sobrecostos por almacenamiento remanente.

Respaldo de la base de datos (Amazon RDS)

- Backups automáticos con Point-in-Time Recovery (PITR).
- Retención de backups de 7 a 14 días.
- Snapshot manual antes de cambios importantes.
Recuperación: restauración a cualquier punto dentro del período de retención; ante falla grave, se crea una nueva instancia a partir del snapshot o backup automático.
- La base de datos (Amazon RDS) se configura en modo Multi-AZ, con una réplica síncrona en otra zona y failover automático.
- La parte on-premise (liquidación de pagos) se considera de menor criticidad en tiempo real, por lo que no se aplica el mismo nivel de alta disponibilidad geográfica.

Respaldo de la capa NoSQL (Amazon DynamoDB)

- Point-in-Time Recovery (PITR), con ventana de recuperación de hasta 35 días.
- Backups on-demand antes de cambios estructurales relevantes.
Recuperación: restauración a cualquier segundo dentro de la ventana de PITR, o desde un backup on-demand, sin afectar la disponibilidad de la tabla original.

2.2 Matriz de disponibilidad, escalabilidad, resiliencia y seguridad

Componente	Disponibilidad	Escalabilidad	Resiliencia	Seguridad	Justificación de Negocio
Versionado S3	No aplica directamente	Escala junto con el bucket, sin límite práctico	Recupera versiones ante borrado o sobrescritura accidental	Versiones antiguas heredan las mismas políticas de cifrado y acceso del bucket	Evita pérdida irreversible de material fotográfico de artesanos ante errores humanos u operativos
Replicación S3 misma región	Asegura la disponibilidad de una copia idéntica del contenido dentro de la misma región geográfica	Totalmente elástica e ilimitada, replicando nuevos objetos de forma automática y asíncrona hacia el bucket secundario.	Resguarda la continuidad operativa de los elementos gráficos al desacoplar el almacenamiento en un bucket de destino independiente	El bucket product-images-dr hereda políticas de acceso estrictas y cifrado en reposo propio (SSE-S3 o KMS), previniendo borrados maliciosos.	Protege el catálogo gráfico ante errores humanos críticos de la aplicación, corrupción de datos o borrados accidentales en el origen principal (product-images-prod).
RDS backups + PITR	No aplica directamente	No aplica	Recuperación a un punto en el tiempo específico ante fallos	Backups cifrados con la misma clave KMS de la instancia	Permite revertir errores en precios o stock sin perder el resto del historial transaccional
DynamoDB backups (PITR + on-demand)	No aplica directamente	Escala junto con la tabla, sin gestión manual	Recuperación a un punto en el tiempo (35 días) o desde snapshot on-demand	Backups cifrados de forma administrada por AWS	Resguarda datos operacionales de alto volumen (carrito, sesiones) sin intervención manual del equipo técnico

3 Arquitecturas de nubes públicas, privadas e híbridas

3.1 Propuesta

Se selecciona un modelo de nube híbrida.

Justificación

La mayor parte de la plataforma (catálogo de productos, imágenes en S3, base de datos de productos, aplicación web y respaldos) se implementa en nube pública (AWS). Esto permite aprovechar la escalabilidad, la alta disponibilidad y el modelo de pago por uso, especialmente relevante para un marketplace que enfrenta picos de demanda en fechas comerciales como Fiestas Patrias o Navidad.

La gestión y liquidación de pagos a los artesanos se mantiene en infraestructura on-premise, por dos razones complementarias: (1) una decisión de gobernanza de la organización, que prefiere mantener control directo sobre los flujos financieros, la conciliación de pagos y los procesos contables asociados al traspaso de dinero hacia los artesanos, independientemente de consideraciones puramente técnicas; y (2) la integración con sistemas contables o ERP ya existentes en la empresa, cuya migración no forma parte del alcance de este proyecto.

De esta forma se obtiene una arquitectura híbrida ligera:

- Los componentes de cara al usuario y de alto volumen (imágenes, catálogo, aplicación) operan en la nube pública.
- El componente financiero sensible de liquidaciones permanece on-premise.
- Ambos entornos se conectan de forma segura mediante VPN o enlace dedicado, idealmente redundante.

Esta decisión es coherente con la estrategia de almacenamiento y respaldo definida en las lecciones anteriores: los datos de productos e imágenes siguen residiendo y respaldándose en AWS, mientras que solo la lógica de liquidación de pagos se mantiene fuera de la nube pública.

Para comprender la distribución espacial de los recursos, la segmentación de red en múltiples Zonas de Disponibilidad (us-east-1a y us-east-1b) y los flujos síncronos y asíncronos de la plataforma, se debe tomar como referencia el esquema técnico adjunto en el Anexo: Diagrama de Arquitectura Consolidado.

3.2 Matriz de disponibilidad, escalabilidad, resiliencia y seguridad

Componente	Disponibilidad	Escalabilidad	Resiliencia	Seguridad	Justificación de Negocio
Nube pública (catálogo, imágenes, app)	Alta, apoyada en servicios gestionados multi-AZ	Elástica, pago por uso	Tolerante a fallos por diseño distribuido de AWS	Segmentación de red (subredes públicas/privadas) y cifrado en reposo/tránsito en todos los componentes	Sostiene la operación de cara al cliente en el canal donde ocurre la mayor variabilidad de demanda

Componente	Disponibilidad	Escalabilidad	Resiliencia	Seguridad	Justificación de Negocio
On-premise (liquidación de pagos)	Depende de la infraestructura propia (menor por defecto)	Limitada, dimensionamiento fijo	Depende de los mecanismos propios de la empresa	Control total del perímetro por parte de la organización; sin exposición a internet pública	Mantiene bajo gobernanza directa el circuito financiero sensible y su integración con sistemas contables existentes
Enlace VPN / dedicado	Punto único de dependencia si no hay redundancia	No aplica	Se recomienda enlace redundante para evitar punto único de falla	Tráfico cifrado extremo a extremo entre ambos entornos	Garantiza que la comunicación entre nube y on-premise no se convierta en el eslabón más débil de la arquitectura

4 Escalabilidad de servicios de cómputo

4.1 Propuesta

Para la parte que corre en nube pública (AWS) se implementa:

- Application Load Balancer (ALB): distribuye el tráfico entre las instancias de la aplicación.
- Auto Scaling Group: ajusta automáticamente la cantidad de servidores (EC2) según la demanda.

La parte on-premise (liquidación de pagos) no requiere este mecanismo, dado que su carga es más estable y predecible.

Funcionamiento (en la nube pública)

- El usuario ingresa a la plataforma.
- El tráfico llega primero al Load Balancer.
- El Load Balancer reparte las solicitudes entre las instancias disponibles.
- Auto Scaling monitorea métricas (CPU, cantidad de solicitudes): si la demanda sube, se crean instancias automáticamente; si baja, se eliminan para ahorrar costos.

Integración con el modelo híbrido

Todo el tráfico de usuarios (catálogo, imágenes, carrito, pedidos B2C y B2B) se gestiona en AWS con Auto Scaling y Load Balancer. Solo cuando corresponde liquidar el pago a un artesano, la aplicación en la nube se comunica de forma segura con el sistema on-premise.

Frontend: ¿servidores propios o solo S3 + CloudFront?

Esta decisión depende de tres factores:

1. El método de renderizado de la aplicación:
 - Si es una aplicación de página única (SPA) que solo consume APIs, se puede servir como archivos estáticos desde S3.
 - Si utiliza un enfoque de renderizado en el servidor (SSR), requerirá capacidad de cómputo serverless bajo demanda.
2. El impacto del SEO en el negocio.
3. La necesidad de personalizar el contenido antes del renderizado (por ejemplo, precios diferenciados para clientes B2B).

Dado que la visibilidad comercial vía Google es crítica para “Artesanos Conectados”, se opta por un frontend híbrido. Las páginas de catálogo y producto se generan dinámicamente en el servidor justo antes de mostrarse al usuario mediante la función Lambda Catálogo (SSR), lo que permite que los motores de búsqueda lean e indexen su contenido de manera óptima. Por otro lado, el resto de la interfaz interactiva (checkout, paneles de gestión y la lógica del carro de compras) se procesa a través de la función Lambda Carrito, sirviéndose como una SPA con archivos estáticos alojados en el bucket de Amazon S3 frontend-prod y distribuidos globalmente vía Amazon CloudFront. Esto combina indexabilidad avanzada donde aporta valor comercial con un costo de cómputo mínimo y eficiente en el resto de la aplicación.

4.2 Matriz de disponibilidad, escalabilidad, resiliencia y seguridad

Componente	Disponibilidad	Escalabilidad	Resiliencia	Seguridad	Justificación de Negocio
ALB	Alta disponibilidad nativa al operar de forma redundante en múltiples AZ, distribuyendo el tráfico dinámico de la aplicación (/*) y del catálogo serverless (/productos/*) según sus reglas de escucha.	No representa un cuello de botella; escala de forma automática y elástica en proporción directa al volumen de peticiones concurrentes HTTP/HTTPS que ingresan a la plataforma.	Aísla fallos de infraestructura. Redirige el tráfico de forma transparente solo hacia los Target Groups saludables, gestionando de forma independiente las instancias EC2 y las invocaciones de la Lambda.	Funciona como el único punto de ingreso público de la VPC. Traduce de manera segura las peticiones web externas a tráfico interno hacia la subred privada o llamadas de API hacia el entorno serverless.	Centraliza y unifica la puerta de entrada para cargas tradicionales y serverless, absorbiendo picos masivos de solicitudes durante Fiestas Patrias o Navidad sin degradar la experiencia.
Auto Scaling Group	Garantiza la continuidad del servicio manteniendo siempre activa una capacidad mínima de cómputo redundante distribuida de forma homogénea en dos AZ.	Escalado horizontal automático y reactivo, incrementando o reduciendo el número de instancias EC2 basado en métricas de consumo de CPU y red.	Detecta instancias colgadas o no saludables y las reemplaza automáticamente con servidores nuevos a partir de su AMI base	Ubicado estrictamente dentro de la subred privada. El acceso administrativo se restringe eliminando SSH y utilizando AWS Systems Manager (SSM).	Ajusta dinámicamente el gasto en servidores a la demanda real, evitando el desperdicio financiero por capacidad ociosa fuera de temporada alta.
Lambda Catálogo (SSR)	Alta disponibilidad global gestionada por AWS, respondiendo de forma síncrona a las solicitudes delegadas por el ALB bajo la regla de enrutamiento por ruta (/productos/*)	Escalado inmediato e instantáneo por petición, respondiendo sin fricción ante ráfagas repentinas de usuarios o bots de búsqueda orgánica concurrentes.	Cuenta con Health Checks opcionales mediante su Target Group en el ALB, lo que permite verificar la salud lógica de la función (como fallos de conexión hacia la base de datos RDS).	Utiliza una interfaz de red (ENI) inyectada en la subred privada para conectarse de forma local y segura a RDS, aislando las credenciales y el tráfico de la base de datos del internet público.	Habilita la generación en servidor para que Google indexe los productos (SEO), ampliando de forma masiva la visibilidad comercial de los artesanos.

Componente	Disponibilidad	Escalabilidad	Resiliencia	Seguridad	Justificación de Negocio
Lambda Carrito y Bucket frontend-prod	La SPA se sirve desde la red edge de CloudFront, mientras que la lógica del carro opera con la resiliencia serverless multi-AZ de AWS Lambda.	Los archivos del frontend se distribuyen instantáneamente. El backend del carrito escala bajo demanda por cada clic en tiempo real del usuario.	Si un error lógico corrompe la sesión, el cliente puede reiniciar el flujo. La SPA estática en frontend-prod cuenta con versionado para reversión inmediata de código.	Acceso al bucket restringido mediante Origin Access Control (OAC); las transacciones de la API viajan cifradas estrictamente por HTTPS extremo a extremo	Minimiza drásticamente los costos de cómputo al servir la interfaz interactiva como contenido estático, delegando la potencia a los recursos del cliente.

5 Disponibilidad de aplicaciones en la red

5.1 Propuesta

- Application Load Balancer (ALB), ya definido en la Sección 4.
- Despliegue Multi-AZ: instancias distribuidas en al menos dos Zonas de Disponibilidad dentro de la misma región de AWS.

Cómo se garantiza la continuidad del servicio

- El Load Balancer opera en varias Zonas de Disponibilidad.
- Las instancias del Auto Scaling Group se distribuyen automáticamente entre esas zonas.
- Si una zona falla, el Load Balancer deja de enviar tráfico a sus instancias y continúa operando con las zonas sanas.
- Auto Scaling puede lanzar nuevas instancias en las zonas disponibles para recuperar capacidad.

5.2 Matriz de disponibilidad, escalabilidad, resiliencia y seguridad

Componente	Disponibilidad	Escalabilidad	Resiliencia	Seguridad	Justificación de Negocio
Multi-AZ (aplicación)	Continuidad si una AZ cae	Escalado distribuido entre AZ	Tolerancia a fallos de zona completa	Grupos de seguridad consistentes en ambas zonas, sin diferencias de exposición	Evita que una falla de infraestructura de AWS se traduzca en caída del marketplace durante horas de alto tráfico

6 Disponibilidad de contenidos de aplicaciones en cloud

6.1 Propuesta

Se incorpora Amazon CloudFront como red de distribución de contenidos (CDN) configurada con una estrategia de origen múltiple para optimizar la velocidad y proteger la infraestructura base.

Funcionamiento

- **Assets Estáticos y SPA (Archivos base):** CloudFront se posiciona directamente delante de los buckets de Amazon S3. El código empaquetado de la interfaz interactiva alojado en frontend-prod y los archivos binarios de fotografías en product-images-prod se almacenan en caché (caching) en los puntos de presencia (Edge Locations) más cercanos a los usuarios. Esto reduce drásticamente la latencia de carga percibida por el cliente y disminuye las peticiones directas de lectura hacia S3.
- **Catálogo Dinámico (SSR):** CloudFront se configura también como la capa de distribución delante de la función Lambda Catálogo. Las páginas HTML del catálogo, generadas dinámicamente en el servidor para favorecer el posicionamiento orgánico, se almacenan en caché en la red perimetral mediante un tiempo de vida corto (TTL de 5 a 10 minutos). Esta ventana de tiempo garantiza que las consultas masivas de los usuarios o las ráfagas automáticas de los bots de indexación (SEO) no impacten de forma directa a la base de datos relacional Amazon RDS (db.t4g.small), blindándola contra cuellos de botella durante picos estacionales de tráfico como Fiestas Patrias o Navidad.

Protección de contenidos

- **Origin Access Control (OAC):** Configurado de forma obligatoria en la comunicación con S3. Esto revoca el acceso público directo a internet de los buckets frontend-prod y product-images-prod, forzando a que cualquier petición deba ser autenticada y canalizada exclusivamente a través de las URLs autorizadas de CloudFront.
- **Cifrado en tránsito:** Todo el tráfico y las comunicaciones de la plataforma se sirven forzosamente bajo el protocolo seguro HTTPS.

6.2 Matriz de disponibilidad, escalabilidad, resiliencia y seguridad

Componente	Disponibilidad	Escalabilidad	Resiliencia	Seguridad	Justificación de Negocio
Amazon CloudFront (CDN)	Alta disponibilidad global garantizada por diseño a través de la infraestructura descentralizada de Edge Locations de AWS.	Absorbe picos masivos de tráfico al servir el contenido directamente desde la caché, eliminando el estrés de cómputo en el origen.	Capacidad de seguir sirviendo el contenido estático almacenado si el origen llega a experimentar cargas altas o latencias de red momentáneas.	Distribución protegida por HTTPS e integración nativa con AWS Shield Standard para mitigar ataques distribuidos de denegación de servicio (DDoS).	Reduce drásticamente los tiempos de carga del catálogo de los artesanos en distintas regiones de Chile, aumentando la conversión de clientes B2C y B2B.

Componente	Disponibilidad	Escalabilidad	Resiliencia	Seguridad	Justificación de Negocio
Origin Access Control (OAC) + HTTPS	No aplica directamente (asumido por el plano de control de CloudFront).	Totalmente elástica; valida firmas de acceso digital sin importar el volumen de peticiones concurrentes.	Protege la integridad y consistencia del catálogo almacenado, eliminando puntos vulnerables de exposición directa a la red pública.	Cifrado SSL/TLS de extremo a extremo. Aplica una política de bucket estricta (Bucket Policy) que rechaza cualquier conexión que no provenga del Service Principal de CloudFront.	Evita la descarga, raspado (scraping) o uso no autorizado de las fotografías de alta resolución de los productos de los artesanos, resguardando un activo comercial clave.

7 Arquitecturas básicas orientadas a mensajes

7.1 Propuesta

Se incorpora una solución combinada de Amazon SNS (Simple Notification Service) y Amazon SQS (Simple Queue Service) para implementar una arquitectura orientada a eventos basada en el patrón de diseño Fan-out.

Flujo principal propuesto

- Origen y Publicación (SNS): Cuando un cliente (B2C o B2B) finaliza con éxito su orden de compra a través de la interfaz procesada por la Lambda Carrito, la aplicación no publica directamente en una cola, sino que envía un único evento de confirmación a un Topic de Amazon SNS.
- Distribución en Abanico (Fan-out): Amazon SNS actúa como el distribuidor central y duplica este evento de forma síncrona e inmediata en paralelo hacia dos destinos independientes:
 - Cola SQS Principal: Recibe los datos detallados del pedido para su procesamiento e inserción en la base de datos de forma segura .
 - Notificaciones Inmediatas: SNS se encarga de gatillar el envío inmediato de alertas por correo electrónico o mensajería hacia el artesano y el comprador, informándoles que la orden ha sido registrada con éxito.
- Procesamiento Asíncrono (SQS): Una vez que el mensaje ingresa a la cola de SQS, la experiencia del usuario queda liberada. En segundo plano, un proceso Worker toma el mensaje de la cola y ejecuta las tareas operativas secundarias: registrar el pedido final en la base de datos relacional Amazon RDS, actualizar el stock crítico consolidado y enviar de forma cifrada los datos de conciliación hacia el centro de datos On-Premise a través de la VPN. Una vez procesado el mensaje con éxito, este es eliminado de la cola.
- Mecanismos de Resiliencia: Para blindar la operación, se incorpora una Dead Letter Queue (DLQ) vinculada a la cola principal de SQS. Si un mensaje experimenta fallas repetidas durante su procesamiento por parte de los Workers (por ejemplo, por una indisponibilidad momentánea en la base de datos o en el canal VPN), se aísla automáticamente en la DLQ tras superar el límite de reintentos, evitando bloqueos lógicos en el flujo principal.

Implementación y Cómputo de los Workers

Para optimizar los recursos y mantener la eficiencia de costos, los Workers encargados de consumir los mensajes de Amazon SQS se implementan como procesos en segundo plano (background daemons) que operan dentro de las mismas instancias Amazon EC2 del Auto Scaling Group ya definidas en la capa de aplicación (Sección 4).

Esta decisión de diseño aporta dos ventajas críticas:

- Eficiencia de Costos (Costo USD 0,00): Al compartir la infraestructura de cómputo elástica ya existente, se evita el aprovisionamiento y el costo mensual adicional de mantener clústeres de contenedores independientes (como ECS/Fargate).
- Escalabilidad Elástica Integrada: Si el volumen de pedidos aumenta drásticamente durante festividades críticas (como Fiestas Patrias o Navidad), la profundidad de la cola SQS crecerá. El procesamiento continuo de los Workers elevará de forma natural el uso de CPU de las instancias EC2, lo que activará automáticamente las políticas de escalado horizontal del Auto Scaling Group, creando más servidores en las subredes privadas para desocupar la cola rápidamente.

7.2 Matriz de disponibilidad, escalabilidad, resiliencia y seguridad

Componente	Disponibilidad	Escalabilidad	Resiliencia	Seguridad	Justificación de Negocio
Amazon SNS + SQS (Colas y DLQ)	Alta disponibilidad completamente gestionada por AWS por diseño, eliminando la necesidad de administrar o parchar servidores de mensajería propios.	Escala de forma automática e ilimitada, adaptándose de manera instantánea a ráfagas masivas de eventos concurrentes sin degradar el rendimiento.	Los mensajes persisten de forma segura en SQS si los Workers fallan. La DLQ aísla transacciones corruptas de manera segura para prevenir bloqueos lógicos en la cola principal.	Cifrado en tránsito y en reposo activado por defecto. Acceso controlado estrictamente por políticas IAM bajo el principio de mínimo privilegio.	Permite implementar el patrón Fan-out para confirmar la compra de inmediato y gatillar múltiples procesos en paralelo (notificaciones y base de datos) sin acoplar los sistemas.
Workers en Auto Scaling Group	Distribuidos de forma redundante a lo largo de las múltiples Zonas de Disponibilidad (us-east-1a y us-east-1b) de la VPC.	El número de hilos de procesamiento se expande o contrae horizontalmente junto con el número de instancias EC2 del Auto Scaling Group.	Visibility Timeout: Si una instancia EC2 se cae inesperadamente procesando una orden, el mensaje no se pierde; regresa automáticamente a SQS tras expirar el tiempo para ser tomado por otra instancia sana.	Ejecutan dentro de la subred privada. No tienen exposición directa a internet y solo cuentan con credenciales de lectura/escritura limitadas hacia la cola asignada.	Garantiza la cero pérdida de transacciones comerciales frente a fallas imprevistas de infraestructura, eliminando la necesidad de soporte manual para recuperar pedidos truncados.

8 Administración de costos en la nube

Para estimar los costos mensuales de la arquitectura propuesta se utilizó la calculadora Cloudcraft, complementada con un cálculo manual para los componentes ALB, Mensajería y CloudFront (no disponible de forma nativa en la herramienta). Los parámetros de tráfico y almacenamiento se definieron de forma conservadora, acorde a una empresa en etapa inicial de modernización tecnológica, evitando el sobredimensionamiento de recursos. A continuación, se detallan los supuestos técnicos utilizados para cada servicio, de manera que el cálculo pueda ser replicado o ajustado ante cambios en el volumen real de operación.

8.1 Supuestos técnicos por servicio (Región: us-east-1)

S3 (3 buckets)

Bucket	Nombre	Storage	PUT/mes	GET/mes
Imágenes de productos	product-images-prod	65 GB	20.000	30.000
Réplica (DR)	product-images-dr	65 GB	0	0
Frontend estático	frontend-prod	5 GB	100	120.000

RDS Multi-AZ

- Instancia db.t4g.small (Graviton2, 2 vCPU, 2 GiB) × 2 (primary + standby síncrono).
- 20 GB General Purpose SSD (gp3) replicados (Multi-AZ) para la base de datos transaccional.

DynamoDB

- Dataset 5 GB · 18M read units/mes · 6M write units/mes · Consistencia eventual.

EC2

- Instancia t4g.small (Graviton2, 2 vCPU, 2 GiB) × 2 (mínimo del Auto Scaling Group).

Balanceador (ALB)

- Bytes procesados: 1 GB/hora · Conexiones nuevas promedio: 25/segundo.

Lambda

- Catálogo. Memoria: 512 MB · Invocaciones: 25.000/mes · Duración promedio: 300 ms
- Carrito. Memoria 256 MB · Invocaciones: 10.000/mes · Duración promedio: 200 ms
- El costo total esta debajo del límite exento del AWS Always Free Tier (1 millón de peticiones y 400.000 GB-segundos), resultando en un costo neto facturado de USD 0,00

CloudFront

- En el modelo de facturación de AWS, la transferencia de datos saliente desde S3 con destino a CloudFront está completamente bonificada a \$0.00 USD/GB dentro de la misma región de forma ilimitada. Por su parte, la entrega desde CloudFront hacia Internet es gratuita gracias al AWS Always Free Tier, que exime de costo los primeros 1 TB (1024 GB) de salida y las primeras 10 millones de solicitudes HTTPS mensuales. Al no superar estos límites, el costo de distribución para la empresa es de \$0,00 USD.

SQS + SNS


- Volumen de mensajes dentro del free tier mensual (1M solicitudes gratis), por lo que el costo es \$ 0,00 USD.
- Se asume que el costo base de los VPC Interface Endpoints para la mensajería privada queda absorbido dentro del presupuesto de conectividad híbrida o se considera despreciable para la fase inicial de simulación frente al costo de un NAT Gateway.

Conectividad Híbrida (Networking)AWS Site-to-Site VPN:

- Conexión activa las 24 horas del día entre la VPC de AWS y el centro de datos on-premise para asegurar el tráfico cifrado de las liquidaciones financieras: costo de \$0,05 USD por hora (mes de 720 horas), totalizando \$USD 36,00 mensual.


8.2 Costos calculados con CloudCraft

Figura 8-1: Costo de Buckets S3 = USD 3,23




Category	Type	Name	Region	Count	Unit price	Total cost
storage	s3	product-images-prod	us-east-1	1	\$1,58	\$1,58
storage	s3	product-image-dr (réplica)	us-east-1	1	\$1,50	\$1,50
storage	s3	frontend-prod	us-east-1	1	\$0,15	\$0,15
					TOTAL S3	\$3,23

Figura 8-2: Costo RDS Multi-AZ – PostgreSQL = USD 52,05




Category	Type	Region	Count	Unit price	Total cost	Instance type	Instance size	Role	Engine
database	rds Multi-AZ	us-east-1	1	\$47,45	\$47,45	t4g	small	primary	postgresql
database	gp3 primary	us-east-2	20	\$0,12	\$2,30				
database	gp3 replica	us-east-3	20	\$0,12	\$2,30				
				TOTAL	\$52,05				

Figura 8-3: Costo Base NoSQL – DynamoDB = USD 6,00



Category	Type	Region	Count	Unit price	Total cost
database	dynamodb	us-east-1	1	\$7,25	\$7,25
database	dynamodb always free tier				-\$1.25
				TOTAL	\$6,00

Figura 8-4: Costo Capa de C3omputo = USD 46,80



Category	Type	Region	Count	Unit price	Total cost	Instance type	Instance size	Platform
compute	EC2	us-east-1	2	\$12,26	\$24,53	t4g	small	linux
compute	ALB	us-east-1	1	\$22,27	\$22,27			
compute	lambda	us-east-1	1	\$0,07	\$0,08			
compute	lambda	always free tier			-\$0,08			
				TOTAL	\$46,80			

8.3 Resumen

Categoría	Componente	Valor mensual (USD)
Storage	S3 (3 buckets)	\$3,23
Database	RDS Multi-AZ	\$52,05
Database	DynamoDB	\$6,00
Compute	EC2 (2 instancias)	\$24,53
Compute	Balanceador	\$22,27
Compute	Lambda (free tier)	\$0,00
CDN	CloudFront (free tier)	\$0,00
Mensajería	SQS + SNS	\$0,00
Networking	AWS Site-to-Site VPN	\$36,00
	TOTAL	\$144,08

El costo mensual estimado de \$144,08 USD resulta razonable para una plataforma de comercio electrónico en etapa de modernización, considerando que la arquitectura incorpora mecanismos de alta disponibilidad (RDS Multi-AZ), resiliencia (réplica de S3) y distribución global de contenido (CloudFront) sin incurrir en sobrecostos por sobreaprovisionamiento. Además, componentes clave como Auto Scaling, Lambda y SQS/SNS operan bajo modelos de pago por uso, lo que permite que el gasto real se ajuste automáticamente a la estacionalidad del negocio.

9 Conclusión

La arquitectura final propuesta para “Artesanos Conectados” resuelve con éxito los desafíos de estacionalidad y disponibilidad del marketplace a través de un modelo de nube híbrida coherente, robusto y financieramente transparente. La migración de las cargas críticas (catálogo, imágenes y procesamiento de órdenes) a la nube pública de AWS dota a la empresa de una infraestructura elástica capaz de absorber picos de tráfico en Fiestas Patrias o Navidad mediante Auto Scaling y colas SQS, sin incurrir en gastos fijos excesivos fuera de temporada.

A lo largo del diseño, cada componente fue optimizado para blindar la operación y la base de datos transaccional RDS Multi-AZ. La integración de Amazon CloudFront no solo reduce la latencia de las imágenes, sino que actúa como una capa defensiva al cachear el contenido dinámico del catálogo por periodos cortos, evitando cuellos de botella en el motor relacional ante consultas masivas o bots de indexación orgánica. Del mismo modo, el uso de Amazon SQS garantiza que ante fallos inesperados de los workers ejecutados en las instancias EC2, los pedidos queden preservados en la cola de mensajería para su reintento automatizado, eliminando el riesgo de pérdida de transacciones B2C o B2B.

Finalmente, la administración de costos entrega un presupuesto realista y sincerado de USD 144,08 mensuales, el cual incorpora proactivamente componentes que suelen omitirse en fases teóricas, tales como la tarifa de conexión por hora de la AWS Site-to-Site VPN y el aprovisionamiento de almacenamiento gp3 en Multi-AZ. Esto demuestra que es factible edificar una arquitectura híbrida de alta disponibilidad, segura (con cifrado extremo a extremo y aislamiento de red) y totalmente tolerante a fallos bajo un modelo de inversión altamente eficiente y ajustado a la realidad del negocio.

10 Anexo: Diagrama de Arquitectura Consolidado

Esquema técnico de la infraestructura híbrida de "Artesanos Conectados" desarrollado en Draw.io, detallando la topología de red de la VPC, el enrutamiento privado mediante AWS PrivateLink (Interface Endpoints) y el desacoplamiento de componentes orientados a eventos mediante el patrón Fan-out (SNS + SQS).

